

ВВЕДЕНИЕ В МАШИННОЕ ОБУЧЕНИЕ

О ПРЕДМЕТЕ И
БЛИЖАЙШИХ СОСЕДЯХ


Москва, 2026

Материалы занятия <https://github.com/kshilin/machine-learning>

2026

РАНХиГС





Что такое машинное обучение?






Что читать в процессе обучения?



Андреас Мюллер, Сара Гвидо



В какой программной среде мы будем работать?



Какие алгоритмы изучим?

Обучение с учителем

Классификация и регрессия

- Ближайшие соседи
- Линейные модели
- Наивные байесовские модели
- Машины опорных векторов
- Деревья решений
- Случайные леса
- Градиентный бустинг на деревьях решений

Обучение без учителя


Кластеризация

- Преобразование данных:
 - стандартизация
 - нормализация
 - обработка категориальных данных
 - анализ главных компонент
- t-SNE
- Кластеризация:
 - k-средних
 - агломеративная
 - DBSCAN
- Поиск аномалий в данных

Параллельно

Контейнеры

- Конструирование пайплайнов
- Отбор наиболее значимых признаков
- Трактовка значимости с использованием векторов Шепли
- Собственные метрики качества
- Регрессия и кластеризация временных рядов



Как строится разработка модели ML




Обучение с учителем:

Этап 1 Подготовка данных (препроцессинг)

Этап 2 Подбор алгоритма машинного обучения

Этап 3 Оценка качества модели и ее улучшение




Как проверить качество алгоритма





Вспомним о матрицах ...

Шахматы



Метрическое пространство

Метрическое пространство есть пара (X, d) , где X — множество, а d — числовая функция, которая определена на декартовом произведении $X \times X$, принимает значения в множестве неотрицательных вещественных чисел, и такова, что

1. $d(x, y) = 0 \Leftrightarrow x = y$ (аксиома тождества).
2. $d(x, y) = d(y, x)$ (аксиома симметрии).
3. $d(x, z) \leq d(x, y) + d(y, z)$ (аксиома треугольника или неравенство треугольника).

При этом

- множество X называется подлежащим множеством метрического пространства.
- элементы множества X называются точками метрического пространства.
- функция d называется метрикой.





Расстояние Минковского порядка p между двумя точками определяется как:

$$\rho(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}.$$


Для $p \geq 1$ расстояние Минковского является метрикой вследствие неравенства Минковского.

Для $p < 1$ расстояние не является метрикой, поскольку нарушается неравенство треугольника.

При $p = \infty$ метрика обращается в расстояние Чебышёва.





Расстояние Миньковского




$$\rho(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}.$$









Решающая граница (2 класса)





Решающая граница (3 класса)



Классификация к ближайшим соседям



Регрессия к ближайшим соседям



Ирисы Фишера


Набор данных «Ирисы Фишера» состоит из данных о 150 экземплярах ириса, по 50 экземпляров из трёх видов:

- Ирис щетинистый (*Iris setosa*),
- Ирис виргинский (*Iris virginica*)
- Ирис разноцветный (*Iris versicolor*).

Для каждого экземпляра измерялись четыре характеристики (в сантиметрах):

- Длина лепестка (англ. sepal length);
- Ширина лепестка (англ. sepal width);
- Длина чашелистика (англ. petal length);
- Ширина чашелистика (англ. petal width).

На основании этого набора данных требуется построить правило классификации, определяющее вид растения по данным измерений. Это задача многоклассовой классификации, так как имеется три класса — три вида ириса.





ПРЕЗИДЕНТСКАЯ
АКАДЕМИЯ

СПАСИБО ЗА ВНИМАНИЕ!

Москва

2026

РАНХиГС