

# ВВЕДЕНИЕ В МАШИННОЕ ОБУЧЕНИЕ

О ПРЕДМЕТЕ И  
БЛИЖАЙШИХ СОСЕДЯХ

Москва, 2024

Материалы занятия

<https://github.com/kshilin/machine-learning>

2024

РАНХиГС

# Что такое машинное обучение?



Как люди видят  
мою работу

$$f(x) = \sum_{i=1}^n w_i x_i + b$$

$$w_i = \sum_{j=1}^m x_j y_j$$

$$f(x) = \sum_{i=1}^n w_i x_i + b$$

$$f(x) = \sum_{i=1}^n w_i x_i + b$$


$$f(x) = \sum_{i=1}^n w_i x_i + b$$

$$f(x) = \sum_{i=1}^n w_i x_i + b$$

Как программисты  
видят мою работу



Как мои друзья  
видят мою работу




Как я вижу  
свою работу




Как мои родители  
видят мою работу

```
>>> from sklearn import svm
```

Что я на самом  
деле делаю



# Что такое машинное обучение?



# Какие пререквизиты?


## НЕОБХОДИМО

- Математический анализ  
минимум 2 семестра
- Алгебра  
минимум 1 семестра
- Теория вероятностей и  
математическая статистика  
минимум 1 семестр

## ЖЕЛАТЕЛЬНО

- Методы оптимизации  
1 семестр
- Анализ данных (на Python)  
1 семестр
- Программирование (на Python или R)  
2 семестра





При минимуме входных знаний учиться можно, но очень сложно






# Что читать в процессе обучения?



Андреас Мюллер, Сара Гвидо



# В какой программной среде мы будем работать?



# Какие алгоритмы изучим?

## Обучение с учителем

### Классификация и регрессия

- Ближайшие соседи
- Линейные модели
- Наивные байесовские модели
- Машины опорных векторов
- Деревья решений
- Случайные леса
- Градиентный бустинг на деревьях решений

## Обучение без учителя

### Кластеризация


- Преобразование данных:
  - стандартизация
  - нормализация
  - обработка категориальных данных
  - анализ главных компонент
  - t-SNE
- Кластеризация:
  - k-средних
  - агломеративная
  - DBSCAN
- Поиск аномалий в данных

## Дополнительно

### Контейнеры

- Конструирование пайплайнов
- Отбор наиболее значимых признаков
- Трактовка значимости с использованием векторов Шепли
- Собственные метрики качества
- Регрессия и кластеризация временных рядов

# С каким фреймворком мы научимся работать?




# Как строится разработка модели ML

Обучение с учителем:




Этап 1 Подготовка данных (препроцессинг)

Этап 2 Подбор алгоритма машинного обучения

Этап 3 Оценка качества модели и ее улучшение






# Как проверить качество алгоритма



# Пятиминутка математики ...

# Шахматы



# Метрическое пространство

Метрическое пространство есть пара  $(X, d)$ , где  $X$  — множество, а  $d$  — числовая функция, которая определена на декартовом произведении  $X \times X$ , принимает значения в множестве неотрицательных вещественных чисел, и такова, что

1.  $d(x, y) = 0 \Leftrightarrow x = y$  (аксиома тождества).
2.  $d(x, y) = d(y, x)$  (аксиома симметрии).
3.  $d(x, z) \leq d(x, y) + d(y, z)$  (аксиома треугольника или неравенство треугольника).

При этом

- множество  $X$  называется подлежащим множеством метрического пространства.
- элементы множества  $X$  называются точками метрического пространства.
- функция  $d$  называется метрикой.





Расстояние Минковского порядка  $p$  между двумя точками определяется как:

$$\rho(x, y) = \left( \sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}.$$


Для  $p \geq 1$  расстояние Минковского является метрикой вследствие неравенства Минковского.

Для  $p < 1$  расстояние не является метрикой, поскольку нарушается неравенство треугольника.

При  $p = \infty$  метрика обращается в расстояние Чебышёва.





# Расстояние Миньковского





$$\rho(x, y) = \left( \sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}.$$









## Решающая граница (2 класса)





## Решающая граница (3 класса)



# Классификация к ближайшим соседям



# Регрессия к ближайшим соседям



# Ирисы Фишера

Набор данных «Ирисы Фишера» состоит из данных о 150 экземплярах ириса, по 50 экземпляров из трёх видов:


- Ирис щетинистый (*Iris setosa*),
- Ирис виргинский (*Iris virginica*)
- Ирис разноцветный (*Iris versicolor*).

Для каждого экземпляра измерялись четыре характеристики (в сантиметрах):

- Длина лепестка (англ. sepal length);
- Ширина лепестка (англ. sepal width);
- Длина чашелистика (англ. petal length);
- Ширина чашелистика (англ. petal width).

На основании этого набора данных требуется построить правило классификации, определяющее вид растения по данным измерений.

Это задача многоклассовой классификации, так как имеется три класса — три вида ириса.



**СПАСИБО ЗА ВНИМАНИЕ!**

Москва

2024

РАНХиГС